Detección de URLs de *phishing* mediante aprendizaje supervisado sobre el conjunto de datos PhiUSIIL

Julián Andrés Agudelo Echeverri, Mateo Reyes Uribe, Cristian Lizarazo Camaño
Facultad de Ingeniería, Universidad de Antioquia
Curso: Introducción al Machine Learning
Correo: julian.agudelo1@gmail.com, mateo.reyesu@udea.edu.co, cristian.lizarazoc@udea.edu.co

***Resumen*—El *phishing* basado en URLs es una de las amenazas de ingeniería social más extendidas y las listas negras tradicionales no alcanzan a cubrir los sitios creados cada día. Este trabajo aborda la detección automática de URLs de *phishing* como un problema de clasificación binaria supervisada, empleando el conjunto de datos público PhiUSIIL (235.795 URLs y 54 características léxicas, derivadas y del código HTML). En este avance se presentan la descripción del problema, el análisis exploratorio de los datos y una revisión del estado del arte sobre el mismo problema y conjunto de datos.**

***Index Terms*—phishing, detección de URLs, clasificación, aprendizaje supervisado, seguridad informática.**

I. Introducción

El *phishing* es un ataque en el que un sitio web fraudulento suplanta a una entidad legítima para robar credenciales o información financiera de los usuarios. Las defensas basadas en listas negras son reactivas: solo bloquean URLs ya reportadas, por lo que fallan ante los sitios nuevos, que tienen además un tiempo de vida muy corto. Esto motiva el uso de *machine learning* para aprender, a partir de características de la URL y de la página, patrones que permitan clasificar un sitio como legítimo o fraudulento de forma automática y anticipada.

El objetivo de este proyecto es construir y validar un modelo de aprendizaje supervisado que clasifique una URL como legítima o de *phishing* a partir del conjunto de datos PhiUSIIL [1]. Este documento corresponde al avance parcial y cubre dos secciones: la descripción del problema con su análisis exploratorio (Sección II) y la revisión del estado del arte (Sección III). El código que reproduce los resultados está disponible en el repositorio del proyecto[1].

II. Descripción del problema

II-A. Contexto y utilidad de la solución

Se busca decidir, de forma automática, si una URL corresponde a un sitio legítimo o a uno de *phishing*. Una solución basada en ML es útil porque generaliza a URLs no vistas (a diferencia de las listas negras), puede integrarse en navegadores, clientes de correo o *gateways* de red, y opera en tiempo casi real. El reto es mantener una alta tasa de detección con una baja tasa de falsos positivos, ya que bloquear sitios legítimos degrada la experiencia del usuario.

[1]https://github.com/mateor32/proyecto-modelos2-phishing

II-B. Descripción del conjunto de datos

El conjunto de datos PhiUSIIL [1], disponible en el UCI Machine Learning Repository, contiene **235.795 muestras** y **54 características** más la variable objetivo. Cada muestra representa una URL y su página web asociada. Las clases se distribuyen en **134.850 URLs legítimas** (`label`=1, 57,2 %) y **100.945 URLs de *phishing*** (`label`=0, 42,8 %), por lo que el problema está *moderadamente balanceado* (Fig. 1). Las características se agrupan en tres familias:

- **Léxicas/estructurales de la URL:** `URLLength`, `DomainLength`, `NoOfSubDomain`, `NoOfDegitsInURL`, `SpacialCharRatioInURL`, `IsDomainIP`, entre otras.
- **Derivadas:** `URLSimilarityIndex`, `CharContinuationRate`, `TLDLegitimateProb`, `URLCharProb`, calculadas por los autores a partir de otras variables.
- **Del código HTML:** `LineOfCode`, `HasTitle`, `HasFavicon`, `IsResponsive`, `HasPasswordField`, `NoOfJS`, `HasCopyrightInfo`, `HasSocialNet`, etc.

Además hay cuatro variables de texto: `URL`, `Domain`, `TLD` y `Title`. En cuanto a tipos, 50 variables son numéricas (de las cuales 19 son binarias 0/1) y 4 son de texto/categóricas.

Datos faltantes y repetidos. El conjunto *no presenta valores faltantes* en ninguna columna, por lo que no se requiere una estrategia de imputación. Tampoco existen filas completamente duplicadas, pero 425 filas repiten una URL ya presente (sin conflicto de etiqueta) y 5.526 dominios tienen más de una fila, con 21.235 muestras en total (p. ej. `ipfs.io`, con 1.197); 54 de esos dominios tienen URLs de ambas clases. Por ello, antes de particionar se eliminarán las URLs repetidas y la partición se hará por dominio, de modo que un mismo dominio no aparezca a la vez en entrenamiento y prueba.

Codificación de variables. Las variables de texto `URL`, `Domain` y `Title` tienen una cardinalidad cercana al número de muestras (p. ej. 235.370 URLs únicas), por lo que son prácticamente identificadores y no se codifican con *one-hot*; se descartan como variables directas o se reservan para una posible extracción de características de texto. La variable `TLD` tiene 695 categorías sin orden; dado que un *one-hot* generaría

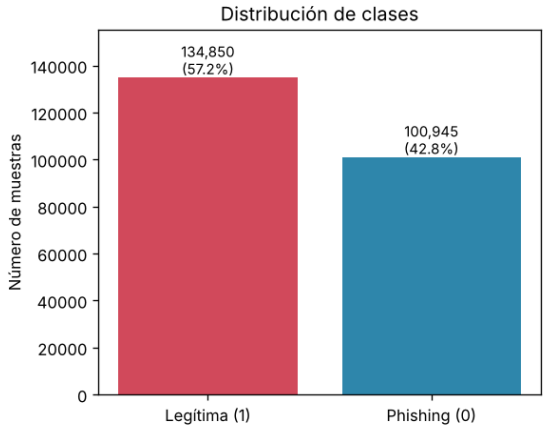


Figura 1. Distribución de clases del conjunto PhiUSIIL (57,2 % legítimas, 42,8 % phishing).

cientos de columnas dispersas, se opta por usar la variable numérica `TLDLegitimateProb` (que ya codifica el TLD como una probabilidad) o una codificación por frecuencia. Las variables numéricas tienen escalas muy distintas y colas largas (p. ej. `LineOfCode` con máximo de 442.666), por lo que se aplicará **estandarización** (`StandardScaler`) para los modelos sensibles a la escala, ajustada solo sobre el conjunto de entrenamiento.

II-C. Análisis exploratorio

El análisis de correlación muestra que varias características del código HTML y derivadas separan bien las clases: `URLSimilarityIndex` ($\rho \approx 0{,}86$), `HasSocialNet` (0,78), `HasCopyrightInfo` (0,74) y `IsHTTPS` (0,61). Se identificó una posible **fuga de información**: todas las URLs legítimas usan HTTPS y toda URL sin HTTPS es de *phishing*, aunque 49.689 URLs de *phishing* (49,2 %) también usan HTTPS. Además, todas las legítimas tienen `URLSimilarityIndex`=100, frente al 0,78 % del *phishing*, algo esperable porque ese índice compara cada URL con la lista Open PageRank de la que se obtuvieron las legítimas [1]; todas empiezan por `www` (41,4 % del *phishing*) y ninguna tiene ruta ni parámetros (28,2 % del *phishing* sí los tiene). Estos patrones sugieren que parte de la separación proviene de la construcción del conjunto y no de una sola variable, lo que podría inflar el desempeño. Por ello, en las fases de modelado se evaluará el efecto de estas variables y de los distintos grupos de características para valorar si el modelo generaliza. El detalle del EDA (dimensiones, tipos, duplicados, cardinalidad, distribuciones y correlaciones) se encuentra en el notebook del repositorio, que comparte las mismas secciones de este informe.

II-D. Paradigma de aprendizaje

El problema se enmarca en el **aprendizaje supervisado**, ya que se dispone de un conjunto de pares etiquetados $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N}$ con $y_i \in \{0, 1\}$. Como la variable de salida es categórica (legítima / phishing), se trata de un problema de **clasificación binaria**. Este paradigma es el apropiado porque el objetivo es predecir una etiqueta conocida a partir de ejemplos previos, y no descubrir estructura latente (lo que correspondería a aprendizaje no supervisado). Dado el balance moderado de clases y la repetición de dominios, se usará una partición **estratificada y agrupada por dominio** y, además de la exactitud, se reportarán métricas robustas al desbalance como F1, *balanced accuracy*, MCC y el área bajo la curva ROC (AUC).

III. Estado del arte

La Tabla I resume trabajos que abordan la detección de *phishing* por URL usando el conjunto de datos PhiUSIIL. El trabajo original [1] introduce el conjunto de datos y un marco de detección basado en un *índice de similitud* de la URL y *aprendizaje incremental*, que permite actualizar el modelo ante URLs nuevas. Posteriormente, [2] propone una red neuronal profunda con mecanismo de atención *multi-head* (ADUIN) orientada a la detección de ataques de día cero, sobre un corpus que combina PhiUSIIL con datos de Kaggle y Mendeley, mientras que [3] compara algoritmos clásicos (Random Forest, SVM, Naïve Bayes y una red MLP) y reporta exactitudes superiores al 99 % sobre PhiUSIIL. Finalmente, [4] estudia métodos de selección de características con 20 variables de la URL, pues excluye las del contenido de la página y trata `URLSimilarityIndex` y `TLDLegitimateProb` como fuga de información; con LASSO ($k = 5$ variables) obtiene un F1 equivalente al de las 20 variables.

Una métrica ajena a la sesión de métricas del curso que aparece en [3] es la **pérdida logarítmica**, que penaliza las probabilidades mal calibradas:

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log p_i + (1 - y_i)\log(1 - p_i)\right], \qquad (1)$$

donde p_i es la probabilidad estimada de la clase positiva. La detección de día cero de [2] es la proporción de URLs de *phishing* no vistas que se detectan. Las demás métricas reportadas (exactitud, precisión, *recall*, F1, MCC, FPR y AUC) se estudiaron en el curso.

Observación. Los desempeños reportados sobre PhiUSIIL son muy altos ($> 99\,\%$ en varios casos), lo que es coherente con la fuerte asociación de algunas características con la etiqueta observada en el EDA. Esto, junto con la exclusión de variables hecha en [4], refuerza la necesidad de un protocolo de validación cuidadoso en las fases siguientes del proyecto.

Referencias

[1] A. Prasad and S. Chandra, "PhiUSIIL: A diverse security profile empowered phishing URL detection framework based on similarity index and incremental learning," *Computers & Security*, vol. 136, art. no. 103545, 2024, doi: 10.1016/j.cose.2023.103545.

[2] R. Gobinath and S. Manikandan, "Deep learning-based phishing classification framework for accurate detection using optimized URL intelligence," *Scientific Reports*, vol. 16, art. 15794, 2026, doi: 10.1038/s41598-026-46481-2.

[3] T. M. Bao, K. Shashvat, N. G. Nhu, and D.-N. Le, "A comparative analysis of machine learning algorithms for spam and phishing URL classification," *Computers, Materials & Continua*, vol. 87, no. 2, art. no. 35, 2026, doi: 10.32604/cmc.2025.075161.

Tabla I
TRABAJOS QUE EMPLEAN EL CONJUNTO DE DATOS PHIUSIIL.

Trabajo	**Paradigma**	**Técnica(s)**	**Validación**	**Métricas**	**Resultados**
Prasad & Chandra, 2024 [1] *Computers & Security* (Elsevier)	Supervisado (clasif.)	Índice de similitud de URL + aprendizaje incremental (BernoulliNB, PassiveAggressive, SGD)	Flujo incremental sobre todo el conjunto; preentrenamiento con divisiones de 10:90 a 90:10	Exactitud, precisión, sensibilidad, F1, MCC	99,24 % (incremental); 99,79 % (preentrenamiento, 90:10)
Gobinath & Manikandan, 2026 [2] *Scientific Reports* (Nature)	Supervisado (clasif.)	Red neuronal profunda con atención *multi-head* (ADUIN); *baselines*: SVM, RF, LR. Datos: PhiUSIIL, Kaggle y Mendeley	División 70/15/15 + 10 repeticiones estratificadas (t-test, McNemar)	Exactitud, precisión, recall, F1, FPR, detección día-cero	95 % exactitud; 93 % precisión; 92 % detección día-cero; FPR 3,5 %
Bao *et al.*, 2026 [3] *Computers, Materials & Continua*	Supervisado (clasif.)	Random Forest, SVM, Naïve Bayes, red MLP	Hold-out estratificado 80/20 (+ k-fold)	Exactitud, precisión, recall, F1, ROC-AUC, log-loss	Exactitud: RF 99,99 %; MLP 99,98 %; SVM 99,97 %; NB 99,94 %
Yulianti & Forenziana, 2026 [4] *Formosa J. of Comp. and Inf. Science*	Supervisado (clasif.)	Selección de características (filtro, *wrapper*, embebido/LASSO) con 20 variables de URL	Hold-out estratificado 80/20 + 5-fold estratificado	Exactitud, precisión, recall, F1, ROC-AUC	LASSO (k=5): F1 0,9975 vs. 0,9965 con 20 variables

[4] F. Yulianti and J. Forenziana, "A comparative analysis of feature selection methods for machine learning-based phishing URL detection," *Formosa Journal of Computer and Information Science*, vol. 5, no. 2, pp. 243–258, 2026, doi: 10.55927/fjcis.v5i2.16783.